Приложения на сортиращите алгоритми

Тодор Дуков

Обща информация за някои алгоритми за сортиране

Понякога се оказва много удобно да сортираме входните данни, защото това ни носи полезна информация. За това е хубаво да се знаят различните алгоритми за сортиране и в какво те са добри. Нека ги сравним по тяхната сложност, като:

- $T_{avg}(n)$ е сложността по време в средния случай
- $M_{avg}(n)$ е сложността по памет в средния случай
- $T_{worst}(n)$ е сложността по време в най-лошия случай
- $M_{worst}(n)$ е сложността по памет в най-лошия случай

| име | $T_{avg}(n)$ | $M_{avg}(n)$ | $T_{worst}(n)$ | $M_{worst}(n)$ |
|------------------------|--------------------|-------------------|--------------------|----------------|
| пирамидално сортиране | $\Theta(n\log(n))$ | $\Theta(1)$ | $\Theta(n\log(n))$ | $\Theta(1)$ |
| сортиране чрез сливане | $\Theta(n\log(n))$ | $\Theta(n)$ | $\Theta(n\log(n))$ | $\Theta(n)$ |
| бързо сортиране | $\Theta(n\log(n))$ | $\Theta(\log(n))$ | $\Theta(n^2)$ | $\Theta(n)$ |

Въпреки че алгоритъмът за бързо сортиране е по-бавен в най-лошият случай от този пирамидално сортиране или този за сортиране чрез сливане, практически се оказва, че се справя по-добре. Разбира се другите алгоритми също си имат техните предимства. Пирамидалното сортиране заема малко памет, което е много полезно във вградени системи. Сортирането чрез сливането се оказва по-бърз, когато данните са много големи и се съхраняват във външни устройства (да кажем на твърд диск). Овен тези алгоритми има и други хубави алгоритми като сортиране чрез броене, но за съжаление ние няма да ги разглеждаме тук.

Два алгоритъма

Ще започнем с два често срещани алгоритъма, които се възползват от това, че данните идват сортирани:

- двоично търсене
- алгоритъма за задачата 2-sum

Нека започнем с алгоритъма за двоично търсене:

```
int binary_search(int *arr, int n, int val)
{
    int left = 0, right = n - 1;

    while (left <= right)
    {
        int mid = left + (right - left) / 2;

        if (arr[mid] == val)
            return mid;
        else if (arr[mid] < val)
            left = mid + 1;
        else
            right = mid - 1;
    }

return -1;
}</pre>
```

При подаден сортиран масив от числа arr с размер n и стойност val, функцията binary_search(arr,n,val) ще върне индекс на arr, в който се намира val, ако има такъв, иначе ще върне -1:

Инварианта. При всяко достигане на ред 5 имаме, че стойността val не се намира измежду двата масива arr[0...left-1] u arr[right+1...n-1].

База. При първото достигане имаме, че left = 0 и right = n-1. Наистина стойността val не се намира измежду двата масива arr[0...0-1] и arr[n-1+1...n-1].

Поддръжка. Нека твърдението е изпълнено за някое непоследно достигане на ред 5. Тогава val не се намира измежду arr[0...left-1] и arr[right+1...n-1], и понеже достигането е непоследно, $left \leq right$. Тогава $mid = \left|\frac{left+right}{2}\right|$, откъдето $left \leq mid \leq right$. Трябва да разгледаме следните три случая:

1 сл. arr[mid] = val - това няма как да е изпълнено понеже достигането е нефинално

2 сл. arr[mid] < val — понеже arr е сортиран, няма как val да се намира измежду arr[0...mid], откъдето val не се намира измежду arr[0...mid + 1 - 1] и arr[right + 1...n - 1].

3 сл. arr[mid] > val — напълно дуален на 2 сл.

Терминация. От цикъла можем да излезем по два начина:

- не е изпълнено условието на ред 5 т.е. left > right тогава left $-1 \ge$ right и понеже val не се намира измежду arr[0...left-1] и arr[right+1...n-1], val не се намира във arr[0...n-1]. Накрая алгоритъмът ще върне -1, което наистина е желания резултат.
- изпълнено е условието на ред 9 т.е. arr[mid] = val тогава алгоритъмът връща mid т.е. точно това, което искаме.

Нека сега разгледаме алгоритъма за задачата 2-sum:

```
bool two_sum(int *arr, int n, int target)
   {
2
        int left = 0, right = n - 1;
        while (left < right)</pre>
             if (arr[left] + arr[right] == target)
                 return true;
             else if (arr[left] + arr[right] < target)</pre>
                 ++left;
10
             else
11
                 --right;
12
        }
13
14
        return false;
   }
```

Ще покажем, че при подаден сортиран масив arr с размер n и число target, функцията two_sum(arr,n,target) разпознава дали има $0 \le i < j \le n-1$, за които:

```
arr[i] + arr[j] = target // всяка такава двойка (i, j) ще наричаме \partial ua\partial a
```

Инварианта. При всяко достигане на ред 5 имаме, че всички диади се намират в arr[left...right].

База. При първото достигане имаме, че left = 0 и right = n - 1. Тогава твърдението е тривиално изпълнено. **Поддръжка.** Нека твърдението е изпълнено за някое непоследно достигане на ред 5. Тогава всички диади се намират в arr[left...right] и понеже достигането е непоследно, left < right. Разглеждаме три случая:

```
1 сл. arr[left] + arr[right] = target — това няма как да е изпълнено понеже достигането е нефинално
```

2 сл. arr[left] + arr[right] < target — тогава понеже arr е сортиран, за всяко $left + 1 \le i \le right$ имаме, че $arr[left] + arr[i] \le arr[left] + arr[right] < target$. Това означава, че left не участва в никоя диада във arr[left...right]. Така получаваме, че всички диади се намират в arr[left+1...right]

3 сл. arr[left] + arr[right] > target - напълно дуален на 2 сл.

Терминация. От цикъла можем да излезем по два начина:

- не е изпълнено условието на ред 5 т.е. $left \ge right$ тогава няма диади в arr, и алгоритъмът коректно ще върне false.
- изпълнено е условието на ред 9 т.е. arr[left] + arr[right] = target тогава алгоритъмът връща true т.е. точно това, което искаме.

Двата алгоритъма са доста подобни, използват една често срещана техника – two-pointer. Това е много силен метод за решаване на задачи за търсене в някакво множество от елементи. Започва се с цялото множество и то постепенно се смалява. Разбира се, тук разгледаните алгоритми имат разлика в сложността, поради разликата в стесняването:

- ullet първият алгоритъм има сложност $O(\log(n))$ понеже винаги разликата между left и right намалява двойно
- ullet вторият алгоритъм има сложност O(n) понеже винаги разликата между left и right намалява с единица

Задачи

3adaua 1. Да се напише колкото се може по-бърз алгоритъм find_peak(arr,n), който приема масив от различни числа arr с размер $n \ge 3$, за който има 0 < i < n-1 такова, че arr $[0 \dots i]$ е сортиран възходящо и arr $[i \dots n-1]$ е сортиран низходящо, и връща това i. След това да се докаже неговата коректност, и да се изследва сложността му по време.

Задача 2. Да се напише колкото се може по-бърз алгоритъм search_range(arr, n, val), който при подаден сортиран масив arr с размер n и число val, което се намира в масива, връща най-малкият и най-големият индекс, на който val се намира в arr. След това да се докаже неговата коректност, и да се изследва сложността му по време.

 $3a\partial a$ ча 3. Да се напише колкото се може по-бърз алгоритъм k_sum(arr, n, k, target), който при подаден сортиран масив arr с размер n и числа k \geq 2 и target, връща дали има $0 \leq i_1 < i_2 < \cdots < i_k \leq n-1$, за които:

$$\texttt{arr}[\texttt{i}_1] + \texttt{arr}[\texttt{i}_2] + \dots + \texttt{arr}[\texttt{i}_k] = \texttt{target}$$

След това да се докаже неговата коректност, и да се изследва сложността му по време.

Задача 4. Да се напише колкото се може по-бърз алгоритъм k_closest(arr,n,k,target), който принтира найблизките k числа в arr до target. След това да се докаже неговата коректност, и да се изследва сложността му по време. Може ли да се напише по-бърз алгоритъм при предположение че arr е сортиран?

3adaua 5. Да се напише колкото се може по-бърз алгоритъм sort(arr,n), който приема масив arr с размер n, съставен от числата 0, 1 и 2, и го сортира. След това да се докаже неговата коректност, и да се изследва сложността му по време.

Задача 6. Да се напише колкото се може по-бърз алгоритъм merge_intervals(intervals, n), който приема масив intervals с размер n, съставен от двойки числа, които представят някакъв затворен интервал, и връща нов масив, в който са сляти всички интервали с непразно сечение. След това да се докаже неговата коректност, и да се изследва сложността му по време.

Задача 7. Да се напише колкото се може по-бърз алгоритъм sorted_squares(arr,n), който приема масив arr с размер n, и връща нов масив от квадратите на arr, който е сортиран. След това да се докаже неговата коректност, и да се изследва сложността му по време.